

GeoAI. IA PARA LA AGRICULTURA COLOMBIANA

Modelado Espacio-Temporal de la Soberanía Alimentaria mediante Graph Neural Networks y Datos Abiertos

Proyecto desarrollado mediante una metodología científica reproducible basada en datos abiertos oficiales de Colombia.

FUENTES OFICIALES

DATOS ABIERTOS



EVA

(Evaluaciones Agropecuarias Municipales)



CNA

(Censo Nacional Agropecuario)



Irrigación

(Potencial de riego)



Divipola

(División Político-Administrativa de Colombia)

DATOS EXTERNOS



ERA 5: Análisis Atmosférico Centro Europeo de Predicción Meteorológica (ECMWF)



CHIRPS: Estimaciones de precipitación a partir de pluviómetros y observaciones satelitales



Geometría municipal oficial
(archivo shapefile de límites municipales).



DATASET CIENTÍFICO CERTIFICADO

2006 – 2018



13 GraphData



1.121 municipios



36 variables predictoras



11 modelos evaluados



Modelo Oficial: GraphSAGE



MODELADO
ESPACIAL



ANÁLISIS
ESPACIO-TEMPORAL



SOBERANÍA
ALIMENTARIA



RIESGOS
CLIMÁTICOS



INTELIGENCIA
ARTIFICIAL

INVESTIGADORES

ID46

John Jairo Prado Piñeres

Adriana María Redondo Alvarado

Gloria Patricia Redondo Alvarado


María José Redondo Alvarado



GITHUB

<https://github.com/johnky100/id46-proyecto-gnn-agricola-ia>

¿POR QUÉ ESTE PROBLEMA MERECE UNA SOLUCIÓN BASADA EN INTELIGENCIA ARTIFICIAL?



GRAFO ESPACIAL OFICIAL - 2018



OBJETIVO

Demostrar que la predicción de los rendimientos agrícolas y los riesgos climáticos constituye un problema estratégico para Colombia y que los enfoques tradicionales presentan limitaciones para resolverlo.



EL PROBLEMA

La producción agrícola colombiana está influenciada simultáneamente por:



Variabilidad climática.



Condiciones territoriales.



Características agrícolas.



Relaciones espaciales entre municipios.



Los métodos radicales presentan dificultades para integrar simultáneamente estas dependencias y generar predicciones que apoyen la toma de decisiones.



PREGUNTA CENTRAL

¿Cómo utilizar Inteligencia Artificial para anticipar rendimientos agrícolas y riesgos climáticos a partir de datos abiertos y relaciones espaciales entre municipios?



MENSAJE CLAVE

El reto no consiste únicamente en predecir el rendimiento agrícola, sino en comprender cómo interactúan el clima, el territorio y la producción para generar información útil para la toma de decisiones.

Si el problema es integrar simultáneamente información climática, agrícola y territorial, la siguiente pregunta es: **¿qué hace diferente nuestra propuesta frente a los enfoques tradicionales?**

¿QUÉ HACE INNOVADORA NUESTRA PROPUESTA?

ENFOQUE TRADICIONAL



DATOS AGRÍCOLAS



MODELO TRADICIONAL



PREDICCIÓN

LIMITACIONES

- ✗ Analiza registros de forma independiente.
- ✗ Escasa integración de datos heterogéneos.
- ✗ No representa explícitamente las relaciones espaciales.
- ✗ Capacidad limitada para evaluar escenarios futuros.

INNOVACIONES DEL PROYECTO

INNOVACIÓN	VALOR AGREGADO
 Integración de datos abiertos	Combina múltiples fuentes oficiales en un único Dataset Científico.
 Modelado mediante Graph Neural Networks	Incorpora explícitamente las relaciones espaciales entre municipios.
 Forecasting espacio-temporal	Permite generar escenarios futuros de producción y riesgo climático.
 Sistema Inteligente GeoAI	Integra dashboard, APIs y agentes de IA para apoyar decisiones.

NUESTRA PROPUESTA



DATOS ABIERTOS



DATOS CLIMÁTICOS



DATOS ESPACIALES



GRAPH NEURAL NETWORKS



FORECASTING



SISTEMA INTELIGENTE GEOAI



APOYO A LA TOMA DE DECISIONES

MENSAJE PRINCIPAL



La innovación no reside únicamente en utilizar Inteligencia Artificial, sino en integrar datos abiertos, relaciones espaciales y análisis predictivo dentro de una metodología reproducible orientada a la toma de decisiones.

La innovación requiere datos de calidad. cómo se construyó un Dataset Científico y fuentes climáticas oficiales.



Por ello, el siguiente paso consiste en mostrar a partir de múltiples fuentes de datos abiertos




FASE 0. DISEÑO CIENTÍFICO DEL PROYECTO



La base científica que guía todo el pipeline

Esta fase no programa absolutamente nada. Su objetivo es definir el problema científico que resolverá todo el pipeline. Consta de ocho etapas que establecen la base metodológica, teórica y operacional del proyecto.

Dominio Científico Agrícola



0.1 DEFINICIÓN DEL PROBLEMA CIENTÍFICO



¿Qué problema científico buscamos resolver?

Modelar y comprender las relaciones espacio-temporales entre los municipios de Colombia que influyen en el rendimiento promedio para la soberanía alimentaria, mediante técnicas de Inteligencia Artificial y GeoAI.

0.2 HIPÓTESIS CIENTÍFICA



Los municipios que presentan similitudes espaciales, climáticas, agropecuarias y socioeconómicas exhiben patrones de rendimiento promedio similares en el tiempo, y estas relaciones pueden ser aprendidas por modelos de Redes Neuronales de Grafos para mejorar la predicción.

0.3 OBJETIVOS DEL MODELO



- Predecir el rendimiento promedio municipal.
- Capturar relaciones espaciales, temporales y multidimensionales entre municipios.
- Generar pronósticos para apoyar la toma de decisiones territoriales.
- Proveer explicabilidad e interpretabilidad científica.

0.4 UNIDAD DE ANÁLISIS



- Municipio (unidad espacial fundamental).
- Observaciones anuales (unidad temporal).
- Cada registro corresponde a un municipio-año.
- Cobertura: Colombia (1.121 municipios).

0.5 VARIABLES DEL ESTUDIO

46 variables científicas agrupadas en:

- Agrícola (8)
- Climática (15)
- Cobertura del suelo (5)
- Espacial (2)
- Geometría (1)
- Identificación (5)
- Índice ambiental (3)
- Riego (1)
- Temporal (1)
- Tenencia de la tierra (4)

Variable objetivo: Logaritmo del rendimiento promedio
Variable objetivo original: Rendimiento promedio

0.6 DISEÑO ESPACIO-TEMPORAL



- Período histórico: 2006–2018 (13 años).
- Resolución temporal: Anual.
- Cobertura espacial: 1.121 municipios de Colombia.
- Enfoque: Panel espacio-temporal dinámico.
- Horizontes de pronóstico: 2019–2035 (17 años).

0.7 ARQUITECTURA CONCEPTUAL



- Grafo multiperspectiva: espacial, climática, agropecuaria y socioeconómica.
- Aprendizaje de representaciones con GNN (GraphSAGE).
- Entrenamiento, validación y prueba espacio-temporal.
- Explicabilidad con GNNExplainer.
- Integración en plataforma GeoAI para análisis y visualización.

0.8 ESPECIFICACIÓN DEL DATASET CIENTÍFICO



- Panel científico integrado y validado.
- 14.573 observaciones (1.121 municipios × 13 años).
- 46 variables científicas.
- Fuentes oficiales y abiertas.
- Dataset certificado, confiable, trazable y reproducible.

FUENTES DE DATOS OFICIALES



EVA
Producción agrícola



CNA
Uso del suelo



Irrigación
Potencial de riego



DIVIPOLA
División político-administrativa



ECMWF - ERA5
Variables climáticas



CHIRPS
Precipitación satelital



Cartografía Municipal
(Municipal) municipal



RESULTADO DE LA FASE 0

Documento de diseño científico del proyecto que define el problema, hipótesis, variables, unidad de análisis, diseño espacio-temporal, arquitectura conceptual y especificación del Dataset Científico.



Esta fase establece la base científica y metodológica que guiará todas las decisiones técnicas y computacionales del pipeline.



Sin una Fase 0 sólida, el proyecto no tiene dirección científica.



FASE 1. CONSTRUCCIÓN DEL DATASET CIENTÍFICO

🌱 Aquí comienza el trabajo de ingeniería de datos

El objetivo de esta fase es construir un único dataset completamente validado, integrado y listo para ser utilizado en la siguiente fase del proyecto.

¿QUÉ CONSTRUIREMOS EN LA FASE 1?

El producto final de esta fase será un
DATASET CIENTÍFICO



2006-2018



1121
municipios



36
variables
predictoras



Variable
objetivo



Sin datos
faltantes



Homologado



Listo para
construir
GraphData

AÚN NO EXISTE EL GRAFO. AÚN NO EXISTE GRAPHSAGE.

1.1 IDENTIFICACIÓN DE FUENTES OFICIALES



- EVA (Evaluaciones Agropecuarias Municipales)
- CNA (Censo Nacional Agropecuario)
- ERA5 (ECMWF)
- CHIRPS (Precipitación satelital)
- DIVIPOLA (División Político-Administrativa)
- Cartografía Municipal
- Otras fuentes complementarias

1.2 DESCARGA DE INFORMACIÓN



- Descarga automática y reproducible
- Almacenamiento organizado por fuente y año
- Control de versiones de los datos crudos
- Registro de metadatos de descarga

1.3 HOMOLOGACIÓN DE IDENTIFICADORES



- Homologación de códigos DIVIPOLA
- Correspondencia municipio-año
- Tratamiento de municipios creados, fusionados o modificados
- Tabla maestra de municipios homologada

1.4 LIMPIEZA DE DATOS



- Detección y tratamiento de outliers
- Estandarización de unidades y formatos
- Tratamiento de valores atípicos
- Imputación controlada (si aplica)
- Eliminación de duplicados e inconsistencias

1.5 INTEGRACIÓN ESPACIO-TEMPORAL



- Unión de todas las fuentes por municipio y año
- Construcción del panel espacio-temporal balanceado
- Cobertura: 2006-2018 (13 años)
- 1121 municipios

1.6 INGENIERÍA DE VARIABLES



- Cálculo de variables derivadas e índices
- Agregaciones espaciales (si aplica)
- Transformaciones (logaritmos, tasas, promedios, etc.)
- Construcción de las 36 variables predictoras y la variable objetivo

1.7 CONTROL DE CALIDAD



- Reglas de validación automática
- Consistencia de rangos, dominios y formatos
- Verificación de cobertura y completitud
- Reporte de calidad por variable y fuente

1.8 VALIDACIÓN CIENTÍFICA



- Validación estadística y descriptiva
- Análisis de correlaciones y distribuciones
- Validación de supuestos del estudio
- Revisión por expertos del dominio

1.9 EXPORTACIÓN DEL DATASET CIENTÍFICO



- Generación del dataset final validado
- Generación de metadatos y diccionarios
- Generación de reportes de calidad y resumen
- Preparación para la Fase 2 (construcción del grafo)

¿QUÉ APRENDEREMOS DURANTE ESTA FASE?

Esta fase responderá preguntas clave como:



- ✓ ¿Qué bases oficiales usar?
- ✓ ¿Cómo integrar EVA, ERA5, CHIRPS, CNA y demás fuentes?
- ✓ ¿Cómo homologar los códigos DIVIPOLA?
- ✓ ¿Cómo tratar municipios creados o modificados?
- ✓ ¿Cómo manejar datos faltantes?
- ✓ ¿Cómo construir un panel balanceado?
- ✓ ¿Cómo validar que el dataset es reproducible?
- ✓ ¿Cómo certificar la calidad del dataset?



PRODUCTO FINAL DE LA FASE 1



DATASET CIENTÍFICO CERTIFICADO



2006-2018
(13 años)



1121
municipios



36
variables
predictoras



Variable
objetivo

✓ SIN DATOS FALTANTES • HOMOLOGADO • LISTO PARA CONSTRUIR GRAPHDATA

RESULTADO ESPERADO



dataset_final.parquet
Dataset final en formato parquet



metadata.json
Metadatos del dataset y del proceso



diccionario_variables.xlsx
Diccionario de variables y definiciones



reporte_calidad.pdf
Reporte completo de calidad y validación



dataset_summary.json
Resumen estadístico del dataset



ESTA FASE ESTABLECE LA BASE CIENTÍFICA Y METODOLÓGICA QUE GUIARÁ TODAS LAS DECISIONES TÉCNICAS Y COMPUTACIONALES



SIN UNA FASE 1 SÓLIDA, EL PROYECTO NO TIENE DIRECCIÓN CIENTÍFICA.

FASE 2. CONSTRUCCIÓN DEL GRAFO CIENTÍFICO

Aquí transformamos el Dataset Científico en la estructura de grafo que utilizará GraphSAGE

Esta fase produce el principal insumo de GraphSAGE. Al finalizar, tendremos 13 GraphData (2006–2018) con topología validada, listos para el modelado.

ENTRADA DE LA FASE 2



DATASET
CIENTÍFICO



2006–2018



1.121 municipios



36 variables predictoras



Variable objetivo



SALIDA DE LA FASE 2
GRAFO CIENTÍFICO
(13 GRAPHDATA)
CERTIFICADOS

2.1

DEFINICIÓN DE LA ESTRUCTURA DEL GRAFO

¿Qué representa cada elemento del grafo?



Nodo
Municipio colombiano



Arista
Relación espacial entre municipios



Atributos del nodo
Variables agrícolas
Variables climáticas
Variables ambientales
Variables de riego
Variables estructurales



Variable objetivo
Producción agrícola
(o la variable objetivo definida)




Grafo
Un año del panel

2.2

CONSTRUCCIÓN DE LOS NODOS


DIVIPOLA
76 001
76 002
76 003
...



- Cada municipio se convierte en un nodo.
- Cada nodo tendrá:
 - ID interno
 - Nombre
 - Código DIVIPOLA
 - Atributos (variables)

2.3

CONSTRUCCIÓN DE LAS ARISTAS



- Se definen las relaciones entre municipios.
- Ejemplos:
 - Palmira — Candelaria
 - Palmira — Pradera
 - Palmira — El Cerrito
- Esta decisión científica condiciona el comportamiento del modelo.




2.4

DEFINICIÓN DE LOS PESOS DE LAS ARISTAS

NO PONDERADO



PONDERADO



Los pesos pueden representar:

- Distancia
- Longitud de frontera
- Similitud climática
- Conectividad vial
- Flujo agrícola
- Combinación de ellas

2.5

INCORPORACIÓN DE ATRIBUTOS DE LOS NODOS

Área sembrada
Producción
Precipitación
Temperatura
Cobertura vegetal
Índice hídrico
Potencial de riego
...



36 VARIABLES

- Se agregan las variables de cada municipio.
- Cada nodo queda completamente caracterizado.

2.6

CONSTRUCCIÓN DE LOS GRAPHDATA

CADA AÑO DEL PANEL SE CONVIERTE EN UN OBJETO GRAPHDATA



Al finalizar: 13 GraphData (2006–2018)

2.7

VALIDACIÓN TOPOLÓGICA



- Número de nodos
- Número de aristas
- Duplicados
- Nodos aislados
- Componentes conexas
- Self-loops
- Simetría
- Consistencia

Validación del grafo, no del dataset.

2.8

ANÁLISIS ESTRUCTURAL DEL GRAFO



Nodos
1.121



Aristas
6.556



Grado promedio
11.70



Densidad
0.0104



Coef. de clustering
0.472



Transitividad
0.374

Estas métricas describen la estructura del sistema territorial que GraphSAGE aprenderá.

2.9

EXPORTACIÓN DEL GRAFO CIENTÍFICO



- Se generan los archivos del grafo, métricas y reportes para su uso en las siguientes fases.
- Producto independiente del entrenamiento.

RELACIÓN CON GRAPH SAGE

Esta fase construye exactamente los componentes que GraphSAGE necesita.

COMPONENTE GRAPH SAGE	SE CONSTRUYE EN	DESCRIPCIÓN
Nodos (x)	2.5 Incorporación de atributos	Matriz de características de los nodos (36 variables).
Aristas (edge_index)	2.3 Construcción de las aristas	Conectividad entre municipios.
Pesos (edge_weight)	2.4 Definición de pesos	Importancia de cada relación entre municipios.
Objetivo (y)	2.5 Incorporación de atributos	Variable objetivo del nodo (producción/rendimiento).
Objeto Data de PyG	2.6 Construcción de los GraphData	Estructura final que utiliza PyTorch Geometric.

MÉTRICAS TOPOLOGICAS EJEMPLO (AÑO 2006)

MÉTRICA	VALOR	DESCRIPCIÓN
Número de nodos	1.121	Municipios representados en el grafo.
Número de aristas	6.556	Relaciones espaciales entre municipios.
Grado promedio	11.70	Conexiones promedio por nodo.
Densidad	0.0104	Proporción de conexiones existentes sobre el total posible.
Coefficiente de clustering	0.472	Tendencia a formar clústeres locales.
Transitividad	0.374	Probabilidad de cierre de triángulos.

PRODUCTOS FINALES DE LA FASE 2

graph_data/
graph_2006.pt
graph_2007.pt
graph_2008.pt
...
graph_2018.pt
graph_metadata.json
topology_metrics.csv
validation_report.pdf



13 GraphData listos para GNN.



Metadatos del grafo y del proceso.



Métricas topológicas y estructurales.



Reporte completo de validación.



RESULTADO ESPERADO DE LA FASE 2



Dataset Científico



Construcción del Grafo



13 GraphData



Topología validada



GraphData certificados



LISTO PARA LA SIGUIENTE FASE

Con los GraphData certificados, el pipeline está listo para avanzar a la fase de modelado con GraphSAGE: Neighbor Sampling, Message Passing y Entrenamiento.



FASE 3. INGENIERÍA DEL MODELO GRAPH SAGE

Construimos la arquitectura del modelo GraphSAGE, pero aún NO se entrena.

El objetivo de esta fase es diseñar, implementar y validar la arquitectura completa del modelo GraphSAGE que utilizará como insumo los GraphData construidos en la Fase 2.

¿QUÉ PRODUCE LA FASE 3



Arquitectura
GraphSAGE
completa



Modelo
GraphSAGE



Listo para
entrenar

AÚN NO SE REALIZA EL ENTRENAMIENTO

3.1

ARQUITECTURA DEL MODELO

Definimos completamente la arquitectura del modelo.




- Número de capas
- Dimensión de embeddings
- Funciones de activación
- Dropout
- Residual connections (opcional)

3.2

NEIGHBOR SAMPLING

Implementamos el muestreo de vecinos para escalar el entrenamiento.



- fanout por capa (ej. [25, 10])
- Muestreo uniforme o ponderado
- Con/ sin remplazo

3.3

FUNCIONES DE AGREGACIÓN

Definimos cómo se agregará la información de los vecinos.



Por defecto usaremos MeanAggregator, pero se mantiene la posibilidad de comparar otros agregadores.

3.4

SAMPLE AND AGGREGATE

Implementación del algoritmo central de GraphSAGE.




Este proceso se repite por cada capa (layer) del modelo.

3.5

CONSTRUCCIÓN DE EMBEDDINGS

Obtenemos la representación vectorial de cada nodo (municipio).




- Embedding resume la información del municipio y su contexto espacial.
- Dimensión típica: 64, 128, 256 (configurable)

3.6

CABEZA DE PREDICCIÓN

Diseñamos la cabeza de predicción para regresión (valor continuo).



GraphSAGE original fue diseñado para clasificación / Link Prediction. Aquí implementamos una cabeza de regresión.

3.7

FUNCIÓN DE PÉRDIDA

Definimos cómo aprenderá el modelo.



No utilizaremos la pérdida del repositorio original porque está diseñada para Link Prediction.

3.8

OPTIMIZACIÓN DEL MODELO

Configuramos el proceso de optimización (sin entrenar).



Se guardan todos los hiperparámetros en un archivo de configuración.

3.9

VALIDACIÓN ARQUITECTÓNICA

Verificamos la consistencia y correctitud de la arquitectura antes de entrenar.

- ✓ Número de parámetros del modelo
- ✓ Dimensiones de entrada y salida
- ✓ Consistencia de capas y conexiones
- ✓ Forward Pass (sin errores)
- ✓ Backward Pass (gradientes válidos)
- ✓ Embeddings generados correctamente

Garantiza que el modelo está listo para el entrenamiento.


RELACIÓN CON GRAPH SAGE

COMPONENTE GRAPH SAGE	SE CONSTRUYE EN	DESCRIPCIÓN
Neighbor Sampling	3.2 Neighbor Sampling	Selecciona un subconjunto de vecinos para escalar.
Agregación	3.3 Funciones de Agregación	Combina la información de los vecinos.
Sample and Aggregate	3.4 Sample and Aggregate	Proceso central que genera el embedding.
Embeddings (x_u)	3.5 Construcción de Embeddings	Representación vectorial de cada nodo.
Predicción ($\hat{y}_u$)	3.6 Cabeza de Predicción	Salida continua (regresión).
Pérdida (L)	3.7 Función de Pérdida	Define el objetivo de aprendizaje.
Optimización	3.8 Optimización del Modelo	Configura el entrenamiento.
Modelo final	3.9 Validación Arquitectónica	Verifica que todo esté correcto antes de entrenar.

RESUMEN DEL FLUJO DE LA FASE 3



CONFIGURACIONES PRINCIPALES DEL MODELO (EJEMPLO)



ENTREGABLE DE LA FASE 3



Modelo GraphSAGE
Listo para Entrenar

- Arquitectura definida
- Componentes implementados
- Configuración guardada
- Validaciones realizadas
- Listo para la Fase 4 (Entrenamiento)



La Fase 3 diseña y valida la arquitectura del modelo GraphSAGE, pero NO realiza el entrenamiento. La siguiente fase (Fase 4) ejecutará el entrenamiento y evaluará el desempeño del modelo.



Una arquitectura sólida en la Fase 3 garantiza un entrenamiento eficiente, reproducible y científicamente robusto.

FASE 4. ENTRENAMIENTO DEL MODELO GRAPHSAGE

Aquí comienza el aprendizaje del modelo.

El objetivo de esta fase es entrenar el modelo GraphSAGE definido en la Fase 3, seleccionar el mejor modelo según su desempeño y garantizar la reproducibilidad y certificación del entrenamiento.



BLOQUE A. PREPARACIÓN DEL ENTRENAMIENTO

4.1 CONFIGURACIÓN DEL EXPERIMENTO

Definimos todos los hiperparámetros del entrenamiento.

- Random Seed: 5477976
- Learning Rate: 0.001
- Batch Size: 1024
- Número de Epochs: 300
- Optimizer: Adam
- Scheduler: ReduceLROnPlateau
- Weight Decay: 1e-5
- Dropout: 0.2
- Hidden Dimension: 128
- Número de Layers: 2
- Neighbor Sampling: [25, 10]
- Device (CPU/GPU): GPU

4.2 DIVISIÓN DEL DATASET

Protocolo espacio-temporal que respeta la cronología.



4.3 CONSTRUCCIÓN DE LOS DATALOADERS

Creamos los cargadores de datos usando NeighborLoader.



BLOQUE B. ENTRENAMIENTO DEL MODELO

4.4 INICIALIZACIÓN DEL ENTRENAMIENTO

Inicializamos todos los componentes del proceso.

- Modelo GraphSAGE
- Optimizador (Adam)
- Scheduler (ReduceLROnPlateau)
- $f(x)$ Función de pérdida (MSE)
- Checkpoints

4.6 VALIDACIÓN POR ÉPOCA


Evaluamos el desempeño después de cada época.

MÉTRICAS POR ÉPOCA						
Época	Train Loss	Val Loss	RMSE	MAE	MAPE	R ²
1	0.2561	0.2314	0.128	0.092	0.065	0.942
50	0.0412	0.0387	0.072	0.053	0.031	0.989
100	0.0328	0.0301	0.059	0.044	0.026	0.991
...	...	...	...	...	...	...
300	0.0217	0.0243	0.048	0.035	0.021	0.994

Permite detectar sobreajuste y seguir la evolución del modelo.


4.7 EJECUCIÓN DEL CICLO DE ENTRENAMIENTO

Cada época recorre todos los batches.



4.7 SELECCIÓN DEL MEJOR MODELO

Seleccionamos el checkpoint óptimo según la métrica de validación.



BLOQUE C. REPRODUCIBILIDAD

4.8 REGISTRO EXPERIMENTAL

Documentamos completamente el experimento.

- Seed: 5477976
- Arquitectura: GraphSAGE (2 capas, 128 dim)
- Learning Rate: 0.001
- Optimizer: Adam
- Batch Size: 1024
- Epochs: 300
- Neighbor Sampling: [25, 10]
- Tiempo de entrenamiento
- Hardware: GPU (NVIDIA RTX ...)
- Versión del código y dependencias

4.9 EXPORTACIÓN DEL MODELO ENTRENADO

Exportamos el modelo y todos los artefactos.



4.10 CERTIFICACIÓN DEL ENTRENAMIENTO

Verificamos que el entrenamiento sea consistente y reproducible.

- ✓ Convergencia alcanzada
- ✓ Estabilidad de las métricas
- ✓ Sin valores NaN o Inf
- ✓ Embeddings válidos
- ✓ Modelo reproducible
- ✓ Checkpoint certificado



RELACIÓN CON EL REPOSITORIO ORIGINAL

ETAPA	MÓDULO / ARCHIVO DE REFERENCIA	ADAPTACIÓN EN TU PROYECTO
4.1 – 4.3	supervised_train.py	Configuración, división espacio-temporal y Dataloaders (NeighborLoader)
4.4 – 4.5	supervised_train.py	Inicialización y ciclo de entrenamiento (forward → loss → backward → step)
4.6 – 4.7	Extensión propia	Validación por época, Early Stopping y selección del mejor modelo
4.8 – 4.10	Extensión propia	Registro, exportación completa y certificación del entrenamiento

RESULTADO FINAL DE LA FASE 4



PRINCIPIOS GARANTIZADOS EN LA FASE 4





CREACIÓN DEL BENCHMARK CIENTÍFICO

Para la Selección del Modelo Oficial

GRAFO TOPOLOGICO 2018
Elaboración Propia

Se evaluaron 11 modelos de 4 familias metodológicas bajo las mismas condiciones experimentales utilizando 7 métricas de evaluación. El Benchmark Científico identifica el modelo con mejor desempeño global y el mejor modelo dentro de la familia GNN.

PANEL CIENTÍFICO (2006-2018)



14.573
OBSERVACIONES



1.121
MUNICIPIOS



13
AÑOS DE INFORMACIÓN
(2006-2018)



46
VARIABLES
CIENTÍFICAS

FUENTES DE DATOS OFICIALES



EVA
Producción agrícola



CNA
Uso del suelo



Irrigación
Potencial de riego



DIVIPOLA
División político-administrativa



ECMWF - ERAS
Variables climáticas



CHIRPS
Precipitación satelital



Cartografía Municipal
(Muni.shp) municipal



ID (5): Código DIVIPOLA del departamento. Código DIVIPOLA del municipio. Identificador único del registro municipio-año. Nombre del departamento. Nombre del municipio.



TENENCIA DE LA TIERRA (4): Porcentaje de tierra arrendada. Porcentaje de tierra con tenencia mixta. Porcentaje de tierra de propiedad colectiva. Porcentaje de tierra en propiedad.



ÍNDICE AMBIENTAL (3): Índice de disponibilidad hídrica. Índice de sostenibilidad territorial. Puntaje promedio de potencial agroambiental.



RIEGO (1): Área con potencial de riego.



TEMPORAL (1): Año de observación.

VARIABLES (46 VARIABLES CIENTÍFICAS)



AGRÍCOLA (8)

Área total sembrada • Logaritmo de la producción total • Logaritmo del área sembrada total • Número de cultivos registrados • Número de grupos de cultivos • Porcentaje de cultivos permanentes • Producción agrícola total • Tasa promedio de cosecha.



CLIMÁTICA (15)

Coefficiente de variación de la precipitación • Componente meridional del viento a 10 metros • Componente zonal del viento a 10 metros • Desviación estándar mensual de la precipitación • Escorrentía superficial • Escorrentía superficial total • Evaporación potencial • Índice de área foliar de vegetación alta • Precipitación acumulada anual • Precipitación mínima mensual • Precipitación total • Radiación térmica descendente en superficie • Tasa de evaporación • Temperatura del aire a 2 metros • Temperatura del punto de rocío a 2 metros.



COBERTURA DEL SUELO (5)

Área total del municipio • Porcentaje de cobertura agropecuaria • Porcentaje de cobertura natural • Porcentaje de otros usos del suelo • Porcentaje de superficie no agropecuaria.



RIEGO (1)
Área con potencial de riego.



TEMPORAL (1)
Año de observación.



ESPACIAL (2)

Latitud geográfica • Longitud geográfica.



GEOMETRÍA (1)

Geometría espacial del municipio.



IDENTIFICACIÓN (5)

Código DIVIPOLA del departamento • Código DIVIPOLA del municipio • Identificador único del registro municipio-año • Nombre del departamento • Nombre del municipio.



ÍNDICE AMBIENTAL (3)

Índice de disponibilidad hídrica • Índice de sostenibilidad territorial • Puntaje promedio de potencial agroambiental.



TENENCIA DE LA TIERRA (4)

Porcentaje de tierra arrendada • Porcentaje de tierra con tenencia mixta • Porcentaje de tierra de propiedad colectiva • Porcentaje de tierra en propiedad.



VARIABLE OBJETIVO (1)

Logaritmo del rendimiento promedio



VARIABLE OBJETIVO ORIGINAL (1)

Rendimiento promedio

BENCHMARK CIENTÍFICO (11 MODELOS)

No	Modelo	Familia	RMSE ↓	MAE ↓	MAPE ↓	R² ↑	Time Train (s) ↓	Time Infer (s) ↓	Loss ↓
1	Linear Regression	Statistical	0,043	0,031	0,018	0,997	0,003	0,000	-
★ 2	GraphSAGE	GNN	0,050	0,036	0,019	0,995	9722814	0,009	0,015
3	TAGCN	GNN	0,055	0,043	0,023	0,994	17990801	0,024	0,016
4	GIN	GNN	0,122	0,092	0,048	0,972	11282040	0,011	0,032
5	CatBoost	ML	0,159	0,112	0,060	0,954	0,662	0,002	-
6	XGBoost	ML	0,165	0,109	0,056	0,951	0,394	0,002	-
7	LightGBM	ML	0,167	0,112	0,058	0,949	1883127	0,030	-
8	Random Forest	ML	0,220	0,157	0,086	0,912	0,488	0,040	-
9	MLP	DL	0,235	0,172	0,094	0,900	1250316	0,000	0,000
10	GCN	GNN	0,364	0,273	0,146	0,751	9582199	0,014	0,143
11	GAT	GNN	0,375	0,285	0,157	0,736	42384001	0,039	0,184

CRITERIOS DE EVALUACIÓN

CRITERIO	MÉTRICA / DESCRIPCIÓN
Precisión predictiva	RMSE, MAE, MAPE, R²
Eficiencia computacional	Tiempo de entrenamiento, Tiempo de inferencia
Representación espacial	Modelado explícito de relaciones espaciales
Aprendizaje sobre grafos	Capacidad de aprender sobre estructuras de grafos
Generalización espacial	Rendimiento en municipios no vistos o distantes
Compatibilidad con forecasting espacio-temporal	Capacidad para realizar predicciones en el espacio y en el tiempo
Compatibilidad con la plataforma GeoAI	Integración y despliegue eficiente en la plataforma GeoAI
Interpretabilidad científica	Facilidad para interpretar resultados y explicar decisiones del modelo



Modelo ganador dentro de la familia GNN: GraphSAGE

Segundo mejor modelo global en términos de precisión predictiva (RMSE).



RESULTADO FINAL

Dataset Científico certificado, confiable, validado y listo para entrenamiento, benchmarking, forecasting y análisis espaciales en la plataforma GeoAI.



PIPELINE COMPLETO: DEL DATASET CIENTÍFICO A LA PLATAFORMA GEOAI

METODOLOGÍA INTEGRADA PARA MODELADO ESPACIO-TEMPORAL



DATOS CONFIABLES

Fuentes oficiales, integradas y validadas.



MODELADO AVANZADO

Grafo espacial + IA para capturar relaciones complejas.



PREDICCIONES INTELIGENTES

Forecasting espacio-temporal para escenarios futuros.



DECISIONES INFORMADAS

Plataforma GeoAI para apoyar políticas públicas y acción territorial.

6

CAPACIDADES DE LA SOLUCIÓN BASADA EN INTELIGENCIA ARTIFICIAL

**OBJETIVO:**

Presentar las funcionalidades que ofrece la solución para apoyar la planificación agrícola y la gestión del riesgo climático mediante Inteligencia Artificial.

**MODELO GNN****PREDICCIÓN ESPACIO-TEMPORAL****FORECAST**

Predicción de rendimientos a nivel municipal

**RIESGO**

Identificación de territorios con mayor riesgo climático

**EXPLICABILIDAD**

Comprensión de las variables y factores que influyen en las predicciones

**ESCENARIOS**

Simulación de diferentes condiciones climáticas y productivas

**APOYO A LA TOMA DE DECISIONES**

Información accionable para la planificación agrícola y la gestión del riesgo climático

PRODUCTOS GENERADOS**MAPAS INTELIGENTES**

Análisis espacial interactivo de predicciones y riesgos

**DASHBOARD**

Visualización dinámica de indicadores y resultados

**REPORTES**

Informes automáticos personalizados

**INDICADORES**

Métricas clave para el monitoreo y evaluación

**RECOMENDACIONES**

Sugerencias de acción basadas en IA

**ALERTAS**

Notificaciones tempranas ante riesgos detectados

CAPACIDADES DEL SISTEMA

CAPACIDAD	DESCRIPCIÓN
 Predicción municipal	Estimar el comportamiento agrícola por municipio.
 Riesgo climático	Identificar territorios con mayor vulnerabilidad climática.
 Escenarios prospectivos	Simular diferentes condiciones climáticas y productivas futuras.
 Explicabilidad	Comprender las variables y factores que influyen en las predicciones.
 Priorización territorial	Identificar municipios para intervención y asignación eficiente de recursos.



La solución no se limita a generar una predicción; transforma los datos abiertos en información útil para apoyar decisiones estratégicas mediante análisis espacial, escenarios prospectivos y herramientas de Inteligencia Artificial.



ANÁLISIS DESCRIPTIVO DEL ARCHIVO forecast_predictions.csv



Resumen de estructura, contenido y hallazgos del conjunto de predicciones generadas por el Modelo Oficial GraphSAGE

1 DESCRIPCIÓN GENERAL



El archivo contiene 19.057 registros distribuidos en 17 años de pronóstico, desde 2019 hasta 2035.



Para cada año se generaron 1.121 predicciones, lo que indica que el modelo produjo una predicción para cada nodo (municipio) representado en el grafo.



La base está compuesta por tres variables: forecast_year: año de pronóstico. node_id: identificador del nodo (municipio). prediction: valor predicho por el Modelo Oficial GraphSAGE.



El conjunto de datos está organizado en formato longitudinal, donde cada municipio posee una predicción para cada uno de los años del horizonte de Forecast.



No existen registros faltantes en las tres variables principales (forecast_year, node_id y prediction).



Cada combinación de año-nodo aparece una única vez, por lo que no se observan duplicados en la estructura del Forecast.



La base constituye un producto listo para ser integrado con información geográfica (DIVIPOLA o cartografía municipal) y así generar mapas temáticos, análisis territoriales y visualizaciones en la plataforma GeoAI.

4 ESTRUCTURA DEL ARCHIVO

VARIABLE	TIPO DE DATO	DESCRIPCIÓN	EJEMPLO
forecast_year	int64	Año del pronóstico (2019 – 2035)	2019
node_id	int64	Identificador del nodo (municipio)	11001
prediction	float64	Valor predicho por el modelo GraphSAGE	1.872345

EJEMPLO DE REGISTROS

forecast_year	node_id	prediction
2019	11001	1.872345
2019	11002	2.341567
...	...	...
2035	11360	1.450872

2 ESTADÍSTICAS GENERALES DE PREDICCIÓN



TOTAL DE REGISTROS

19.057



AÑOS DE PRONÓSTICO

17

(2019 – 2035)



NODOS (MUNICIPIOS)

1.121

por año

DISTRIBUCIÓN TEMPORAL

AÑO	REGISTROS
2019	1.121
2020	1.121
2021	1.121
...	...
2034	1.121
2035	1.121



ESTADÍSTICAS DE LA VARIABLE PREDICTION (GLOBAL)

MÍNIMO



0.694840

MÁXIMO



5.071452

PROMEDIO



2.029578

DESV. ESTÁNDAR



0.721627

3 HALLAZGO IMPORTANTE DEL ARCHIVO



Al analizar exclusivamente el contenido del CSV se observa que las predicciones son exactamente las mismas para todos los años.

Estadísticas por año (observadas en la base de datos)

ESTADÍSTICO	2019	2020	2021	...	2035
Registros por año	1.121	1.121	1.121	...	1.121
Promedio	2.029578	2.029578	2.029578	...	2.029578
Desviación estándar	0.721627	0.721627	0.721627	...	0.721627
Mínimo	0.694840	0.694840	0.694840	...	0.694840
Máximo	5.071452	5.071452	5.071452	...	5.071452

Comparación de promedios por año



VERIFICACIÓN ADICIONAL RECOMENDADA

Antes de concluir que "no hay cambios entre años", habría que verificar si las predicciones para un mismo node_id son exactamente iguales entre 2019 y 2035, o si únicamente coinciden las estadísticas agregadas. Esa verificación requiere comparar las series de cada municipio.

5 CONCLUSIÓN



El archivo forecast_predictions.csv contiene 19.057 predicciones espacio-temporales generadas por el Modelo Oficial GraphSAGE para 1.121 municipios durante 17 años (2019–2035). Los datos están completos, sin duplicados y listos para análisis territorial e integración con información geográfica en la plataforma GeoAI.



Hallazgo observado: las estadísticas agregadas de prediction son idénticas en todos los años. Se recomienda verificar si las predicciones por municipio son exactamente iguales entre años.




Este análisis descriptivo proporciona una visión integral de la estructura y calidad del conjunto de predicciones generado para apoyar la toma de decisiones territoriales.





OBJETIVO

Demostrar cómo el modelo de Inteligencia Artificial se transforma en una herramienta útil para ciudadanos, productores, investigadores y entidades públicas.



CAPACIDADES DEL SISTEMA

	Dashboard GeoAI	Visualización de indicadores y mapas
	Mapa interactivo	Consulta de resultados por municipio
	Agente IA	Responde preguntas sobre los datos y las predicciones
	Reportes automáticos	Generación de informes técnicos en PDF
	API	Integración con otras plataformas
	Sistema de alertas	Identificación de municipios prioritarios

USUARIOS BENEFICIADOS



¿QUÉ HACE DIFERENTE NUESTRA SOLUCIÓN?

	DASHBOARD TRADICIONAL	SISTEMA INTELIGENTE GEOAI
	Visualiza datos	Analiza y recomienda
	Requiere interpretación del usuario	Explica resultados mediante IA
	Consulta estática	Interacción en lenguaje natural
	Reportes manuales	Reportes automáticos
	Información descriptiva	Predicción y escenarios futuros

TOMA DE DECISIONES

Decisiones informadas, oportunas y basadas en evidencia



CASOS DE USO (¿QUÉ PUEDE HACER?)

USUARIO	¿QUÉ PUEDE HACER?
 Ministerio	Priorizar inversiones agrícolas
 Gobernaciones	Identificar municipios con mayor riesgo
 Investigadores	Analizar escenarios climáticos
 Productores	Consultar tendencias y riesgos
 Entidades públicas	Apoyar la planificación territorial



La innovación del proyecto no termina con el desarrollo del modelo predictivo.

El verdadero valor consiste en transformar la Inteligencia Artificial en una herramienta accesible para apoyar decisiones estratégicas mediante mapas, indicadores, reportes y agentes inteligentes.



Basado en
datos abiertos



Inteligencia
Artificial



Análisis
espacial



Impacto
real

8

IMPACTO, ESCALABILIDAD Y VALOR DE LA SOLUCIÓN

Transformando datos abiertos en decisiones que impulsan el desarrollo agrícola sostenible.

**OBJETIVO:**

Sintetizar el valor de la propuesta, destacando su impacto potencial, capacidad de crecimiento y alineación con los objetivos del concurso.

¿QUÉ APORTA ESTA SOLUCIÓN?

COMPONENTE	VALOR GENERADO
 DATOS ABIERTOS	Integra información oficial agrícola, climática y territorial en un único ecosistema de datos.
 INTELIGENCIA ARTIFICIAL	Utiliza Graph Neural Networks para modelar relaciones espaciales y mejorar el análisis predictivo.
 TOMA DE DECISIONES	Genera información para apoyar la planificación agrícola y la gestión del riesgo climático.
 SISTEMA INTELIGENTE GEOAI	Facilita el acceso a mapas, indicadores, reportes y consultas mediante un asistente especializado.

ESCALABILIDAD

-  Incorporación de nuevas fuentes de datos.
-  Integración de nuevos modelos de IA.
-  Adaptación a otros sectores (agua, ambiente, salud o movilidad).

IMPACTO ESPERADO**DATOS ABIERTOS**

Fuentes oficiales confiables

**INFORMACIÓN INTEGRADA**

Ecosistema unificado y consistente

**INTELIGENCIA ARTIFICIAL**

Modelado avanzado y análisis predictivo

**CONOCIMIENTO**

Información accionable y comprensible

**DECISIONES**

Mejores decisiones para el territorio

**IMPACTO SOCIAL**

Desarrollo rural sostenible

**EVIDENCIA PARA DECISIONES**

Información confiable para planificar y priorizar acciones.

**REDUCCIÓN DE RIESGOS CLIMÁTICOS**

Anticipación y gestión oportuna de amenazas.

**MAYOR EFICIENCIA EN RECURSOS**

Optimización de inversiones y programas.

**INCLUSIÓN Y ACCESO A LA INFORMACIÓN**

Herramienta accesible para múltiples actores.

**ESCALABLE Y REPLICABLE**

Adaptable a nuevos territorios y problemáticas.



La propuesta transforma datos abiertos en una herramienta de apoyo a la decisión, combinando Inteligencia Artificial, análisis espacial y una plataforma interactiva con potencial de escalarse a otros territorios y dominios.

